

Klasifikasi Penyakit Daun Jagung Menggunakan Model Deep Learning EfficientNetB5

Corn Leaf Disease Classification Using the EfficientNetB5 Deep Learning Model

Rima Tri Wahyuningrum¹⁾, Rio Erfian²⁾, Ari Kusumaningsih³⁾, Hapsari Peni Agustin Tjahyaningtijas⁴⁾

^{1, 2, 3} Teknik Informatika, Fakultas Teknik, Universitas Trunojoyo Madura, Indonesia

⁴ Teknik Elektro, Fakultas Teknik, Universitas Negeri Surabaya, Indonesia

rimatriwahyuningrum@trunojoyo.ac.id ¹⁾

Diterima: 11 Agustus 2024 || Direvisi: 15 Desember 2024 || Disetujui: 15 Maret 2025

Abstrak – Jagung adalah tanaman pangan utama di Indonesia setelah padi, namun rentan terhadap berbagai penyakit daun seperti karat, bercak abu-abu, dan hawar utara. Klasifikasi dengan *Machine Learning* konvensional memerlukan ekstraksi fitur manual untuk hasil optimal, mengilhami penciptaan model *Deep Learning* EfficientNetB5 dalam penelitian ini. Model ini diuji dengan *dataset* berisi 3.852 citra yang dibagi menjadi 4 kelas. Hasil eksperimen menunjukkan bahwa kombinasi *hyperparameter*: *learning rate* = 0,0001 dan *batch size* = 32 menghasilkan kinerja tertinggi dibandingkan dengan model lainnya, dengan akurasi 96,27%, presisi 90,90%, spesifisitas 97,55%, serta sensitivitas 88,13%. Hal ini menandakan kemajuan signifikan dalam klasifikasi penyakit daun pada tanaman jagung.

Kata Kunci: klasifikasi, penyakit daun jagung, *Deep Learning*, EfficientNetB5, *learning rate*, *batch size*

Abstract – The second most important food crop in Indonesia, after rice, is corn, which is highly susceptible to leaf diseases such as common rust, cercospora gray leaf spot, and northern leaf blight. In spite of traditional Machine Learning, in which manual feature extraction must be impeccable for optimal results, a model capable of accurate classification is required. In this investigation, the Deep Learning model EfficientNetB5 is used to classify corn leaf diseases, and the performance model between learning rate and batch size hyperparameters is compared. All models are identical to the dataset, which consists of 3,852 images divided into 4 classifications. The testing results indicate that the combination of learning rate = 0.0001 and batch size = 32 obtains the highest value compared to other models. The obtained evaluation values were 96.27 % accuracy, 90.90 % precision, 97.55% specificity, and 88.13 % sensitivity.

Keywords: classification, corn leaf disease, Deep Learning, EfficientNetB5, learning rate, batch size

PENDAHULUAN

Jagung merupakan tanaman pangan utama kedua setelah padi di Indonesia dan menempati posisi ketiga setelah padi dan terigu di dunia (Sudjono, 1988). Akan tetapi semakin berkembang pesatnya industri peternakan, jagung sebagai komponen utama dalam ransum pakan dengan persentase sebesar 60%. Kebutuhan jagung nasional diperkirakan lebih 55% diperuntukkan sebagai pakan, dan 30% sebagai konsumsi pangan, lalu sisanya sebagai kebutuhan industri dan benih (Amzeri, 2018).

Penelitian tentang identifikasi penyakit daun jagung sudah pernah dilakukan, seperti Zhang Z, dkk (Zhang et al., 2015) pada tahun 2015 mengusulkan metode GA-SVM (Genetic Algorithm Support Vector Machine) mengkombinasikan algoritma evolusi dan algoritma *machine learning* untuk mengklasifikasikan

penyakit daun jagung. Seiring perkembangan teknologi, metode *deep learning* banyak diterapkan untuk proses klasifikasi (Hasan Mahmud et al., 2019) dikarenakan memiliki keunggulan dari pada algoritma *machine learning* (Quintal Lauzon, 2012).

Selanjutnya pada tahun 2019, Sibiya & Sumbwanyambe (Sibiya & Sumbwanyambe, 2019) menggunakan model *deep learning* Arsitektur CNN untuk mengklasifikasi 3 jenis penyakit daun tanaman jagung. Kemudian pada tahun 2020, Syarieff & Setiawan (Syarieff & Setiawan, 2020) menganalisis klasifikasi citra penyakit daun jagung dengan 2 langkah: Ekstraksi fitur menggunakan 7 model *deep learning* (CNN) berbeda dan klasifikasi menggunakan 3 metode *machine learning*. Pada tahun berikutnya, Wahyuningrum RT, dkk (Wahyuningrum et al., 2021) telah mengimplementasikan model *DenseNet-169* pada klasifikasi penyakit daun jagung yang memperoleh

akurasi sebesar 83,5%. Atila U, dkk (Atila et al., 2021) mengklasifikasikan 39 jenis penyakit tanaman menggunakan menggunakan model EfficientNet B-0 sampai B-7 dan dibandingkan dengan model *deep learning* lainnya. Di tahun 2022, Ivan Pratama dkk juga melakukan penelitian dengan memperoleh akurasi 98,4% pada klasifikasi penyakit daun jagung menggunakan CNN (Pratama Putra & Alamsyah, 2022). Banyak *hyperparameter* perlu disesuaikan seperti, *batch size* dan *learning rate* untuk melatih model *deep learning* agar dapat mengklasifikasikan citra (Sulistyorini et al., 2023). Hal ini diperlukan untuk mendapatkan *batch size* dan *learning rate* yang optimal untuk diterapkan pada model pembelajaran (Kandel & Castelli, 2020; Nugroho & Suhartanto, 2020).

Meskipun banyak penelitian telah mengaplikasikan *deep learning* dalam mengklasifikasikan penyakit daun jagung (Bagas Prakosa & Radius Tanone, 2023), sebagian besar masih bergantung pada model CNN umum yang memiliki keterbatasan pada akurasi, terutama dalam hal parameter optimal seperti *learning rate* dan *batch size* (Lu et al., 2021). Belum ada pendekatan yang mengoptimalkan arsitektur model *EfficientNetB5* untuk penyakit daun jagung dengan penyesuaian *hyperparameter*. Dengan demikian, penelitian ini bertujuan untuk mengisi *gap* penelitian dengan melakukan *tuning hyperparameter* pada model *EfficientNetB5*, yang mampu meningkatkan akurasi klasifikasi penyakit daun jagung.


METODOLOGI PENELITIAN

Penelitian ini menggunakan metode yang terdiri dari tahap *preprocessing* citra, pembagian *dataset*, pelatihan model EfficientNet, dan pengujian citra serta mengevaluasinya. Tahapan yang dilakukan untuk klasifikasi jenis citra daun jagung dimulai dari memasukkan citra daun jagung dan melakukan *preprocessing* citra serta membaginya menjadi dua *set* bagian, yaitu data *training* dan data *testing* menggunakan *k-fold cross validation*. Proses *training* dengan model EfficientNetB5 dilakukan untuk mendapatkan model. Kemudian, pengujian citra dilakukan untuk memperoleh hasil klasifikasi dalam menentukan empat jenis citra daun jagung.

Dataset

Pada penelitian ini, *dataset* yang digunakan adalah citra daun jagung yang dikumpulkan dari repositori *Mendeley data* (Geetharamani & Arun Pandian, 2019)

yang berisikan 60.000-an citra dari berbagai tanaman. Dari total 60.000 citra tanaman yang tersedia di repositori, penelitian ini memilih 3.852 sampel dengan klasifikasi yang spesifik pada daun jagung yang terkena penyakit. Pemilihan ini didasarkan pada ketersediaan data yang jelas dan relevan untuk setiap kelas penyakit daun jagung, serta memastikan kesetaraan jumlah gambar per kelas guna menjaga keseimbangan *dataset*. Selanjutnya citra diklasifikasikan menjadi 4 kelas yaitu, kelas daun sehat (*healthy*), kelas daun berkarat (*common rust*), kelas daun hawar utara (*northern leaf blight*), dan kelas daun bercak abu-abu (*Cercospora Grey leaf spot*). Pada Gambar 1 terlihat contoh citra keempat jenis penyakit daun jagung yang digunakan pada penelitian ini.



Gambar 1 a) Daun Sehat, b) Daun Berkarat, c) Daun Hawar Utara, dan d) Daun Bercak Abu-abu.

EfficientNetB5

Arsitektur EfficientNet adalah salah satu arsitektur tercanggih dengan akurasi mencapai 84,4% dengan jumlah parameter 66 juta pada klasifikasi ImageNet. EfficientNet terdiri dari 8 model antara B0 sampai B7. Jumlah parameter tidak banyak meningkat seiring bertambahnya jumlah model, akan tetapi akurasi meningkat secara nyata. EfficientNet merupakan arsitektur CNN yang menggunakan penskalaan ketiga dimensi *depth*, *width*, dan *resolution* jaringan secara seragam (Tan & Le, 2019).


Dengan demikian, diperoleh jumlah parameter yang lebih rendah, mengakibatkan peningkatan kecepatan dalam proses, tetapi tetap mempertahankan kinerja yang baik dibandingkan dengan arsitektur sebelumnya.

$$\begin{aligned} \text{depth} : d &= \alpha^\phi \\ \text{width} : w &= \beta^\phi \\ \text{resolution} : r &= \gamma^\phi \\ s.t. \alpha \cdot \beta^2 \cdot \gamma^2 &\approx 2 \\ \alpha \geq 1, \beta \geq 1, \gamma \geq 1 \end{aligned} \quad (1)$$

Konstanta α , β , dan γ dapat ditentukan nilainya menggunakan *grid search*. Sedangkan, koefisien ϕ nilainya ditentukan oleh pengguna. Hal ini digunakan untuk mengontrol besarnya sumber daya yang tersedia untuk melakukan penskalaan pada model. Konstanta α , β , γ menentukan bagaimana sumber daya yang ditugaskan ke *depth*, *width*, dan *resolution* jaringan

masing-masing. Kemudian memperbaiki α , β , γ sebagai konstanta dan meningkatkan jaringan dasar dengan \emptyset berbeda menggunakan Persamaan 1, untuk mendapatkan EfficientNet-B1 hingga B7 (Tan & Le, 2019).

Penskalaan tidak mengubah operasi lapisan, oleh karena itu lebih baik terlebih dahulu memiliki jaringan dasar yang baik dan kemudian menskalakannya di sepanjang dimensi yang berbeda menggunakan *compound scalling* (Tan & Le, 2019). Meningkatkan jaringan dasar akan melahirkan keluarga model, yang disebut EfficientNets. Skema arsitektur EfficientNetB5 yang ditunjukkan pada Gambar 2 termasuk dalam keluarga EfficientNets yang merupakan hasil dari penskalaan dari jaringan dasar EfficientNetB0 menggunakan *compound scalling*.



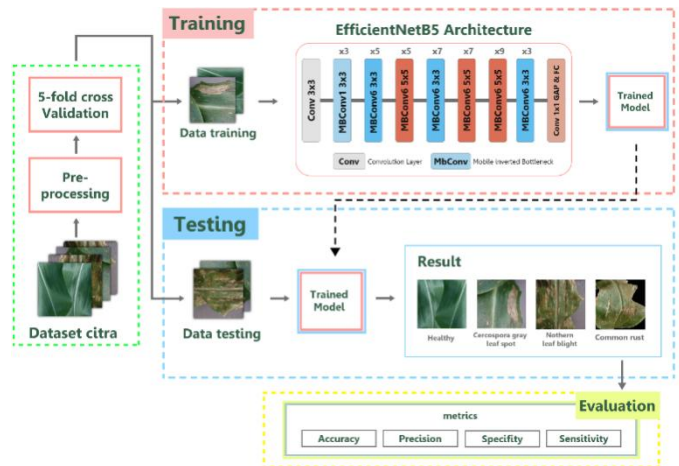
Gambar 2 Arsitektur EfficientNetB5

Diagram Alir

Arsitektur EfficientNetB5 diimplementasikan untuk membangun model pada tahap *training*. Sedangkan pada tahap *testing* digunakan untuk menguji model yang telah dibangun pada tahap *training* sebelumnya. Alur *training* dan *testing* ditunjukkan oleh Gambar 3 yang terdiri dari beberapa proses, yaitu:

1. *Dataset* citra daun jagung dilakukan *preprocessing* terlebih dahulu, melakukan normalisasi pada data citra menjadi data *array*.
2. Setelah normalisasi, *dataset* dibagi menjadi dua bagian: data pelatihan (*training set*) dan data pengujian (*testing set*) dengan menggunakan metode *5-fold cross validation*.
3. Tahap *training*, dilakukan dengan langkah-langkah berikut :
 - a. Memasukkan data *training* hasil normalisasi.
 - b. Data kemudian dilatih dalam arsitektur EfficientNetB5 meliputi proses ekstraksi fitur dan klasifikasi dan menghasilkan model klasifikasi.

- c. Hasil yang didapatkan berupa model klasifikasi hasil proses *training*.
4. Tahap *testing*, dilakukan dengan langkah-langkah berikut :
 - a. Memasukkan data *testing* hasil normalisasi
 - b. Data kemudian diuji dengan model yang telah diproses dari *training*.
 - c. Hasil *testing* berupa evaluasi klasifikasi citra penyakit daun jagung dari kelas daun sehat, daun berkarat, daun hawar utara, dan daun bercak abu-abu.



Gambar 3 Diagram Alir Klasifikasi Penyakit Daun Jagung

Hyperparameter

Banyak *hyperparameter* perlu disesuaikan sebelum melatih CNN untuk mengklasifikasikan citra (Indolia et al., 2018). *Hyperparameter* parameter yang dapat disesuaikan yang memungkinkan mengontrol proses *training* model (Ioffe & Szegedy, 2015). Beberapa *hyperparameter* umum seperti: *learning rate*, *batch size*, jumlah *epoch*, dan fungsi aktivasi. Proses mencari nilai optimal dari *hyperparameter* suatu model untuk memperbaiki performa model disebut *hyperparameter tuning*. Hal ini dilakukan dengan mencoba berbagai nilai *hyperparameter* dan membandingkan hasilnya dengan metrik performa.

Evaluasi Metrik

Evaluasi dilakukan untuk mengetahui seberapa kinerja dari suatu model atau arsitektur. Karena terdapat 4 kelas dalam dataset, maka dilakukan klasifikasi *multi-class* (Nayak et al., 2022). Performa pada model yang dibahas dalam penelitian ini diukur menggunakan metrik yang berbeda seperti akurasi (*Acc*), sensitivitas (*Sen*), spesifisitas (*Spe*) dan presisi (*Pre*). Akurasi menunjukkan tingkat data yang

diklasifikasikan dengan benar dari semua data. Nilai dari akurasi dapat diperoleh dari persamaan 2 untuk kelas k .

$$Acc(k) = \frac{TP(k) + TN(k)}{TP(k) + FN(k) + TN(k) + FP(k)} \quad (2)$$

Sensitivitas adalah rasio positif yang diprediksi dengan benar dari semua positif murni. Nilai dari sensitivitas dapat diperoleh dari persamaan 3.

$$Sen(k) = \frac{TP(k)}{TP(k) + FN(k)} \quad (3)$$

Spesifisitas adalah rasio negatif yang diprediksi dengan benar dari semua negatif yang benar. Nilai dari spesifisitas dapat diperoleh dari persamaan 4.

$$Spe(k) = \frac{TN(k)}{TN(k) + FP(k)} \quad (4)$$

Sedangkan, presisi adalah proporsi positif yang diprediksi dengan benar dari semua identifikasi positif. Untuk memperoleh nilai presisi dengan persamaan 5.

$$Pre(k) = \frac{TP(k)}{TP(k) + FP(k)} \quad (5)$$

Parameter TP mewakili *true positive*, sedangkan TN merujuk pada *true negative*. FP menggambarkan *false positive*, sementara FN adalah *false negative*. Metrik dan perhitungannya diperluas untuk klasifikasi multi-kelas menggunakan rata-rata makro (Sokolova & Lapalme, 2009) dengan persamaan 6, 7, 8, dan 9.

$$Avg Acc = \frac{1}{class} \sum_{k=1}^{class} Acc(k) \quad (6)$$

$$Avg Sen = \frac{1}{class} \sum_{k=1}^{class} Sen(k) \quad (7)$$

$$Avg Spe = \frac{1}{class} \sum_{k=1}^{class} Spe(k) \quad (8)$$

$$Avg Pre = \frac{1}{class} \sum_{k=1}^{class} Pre(k) \quad (9)$$

Kurva ROC

Receiver Operating Characteristic (ROC) adalah kurva yang menunjukkan kinerja model klasifikasi di semua ambang batas klasifikasi (Perdani et al., 2022). Kurva ini menggambarkan dua parameter: *true positive rate* (sensitivitas) dan *false positive rate* (1-spesifisitas). Semakin kurva cembung dan mendekati

pojok kiri atas, semakin baik diskriminasi yang dimiliki model tersebut (Gajowniczek et al., 2014)

HASIL DAN PEMBAHASAN

Tujuan utama dari penelitian ini adalah untuk menguji keberhasilan arsitektur *deep learning* EfficientNet dalam klasifikasi penyakit daun tanaman jagung dengan mencari nilai *hyperparameter learning rate* dan *batch size* yang memiliki kinerja yang optimal. *Learning rate* yang digunakan dalam percobaan ini adalah $LR = [0.001, 0.0001, 0.00001]$ (Chamarty, 2020) dan dua *batch size* digunakan untuk masing-masing *learning rate*, yaitu 16 dan 32 (Kandel & Castelli, 2020) yang dapat disimpulkan berdasar skenario pada Tabel 1.

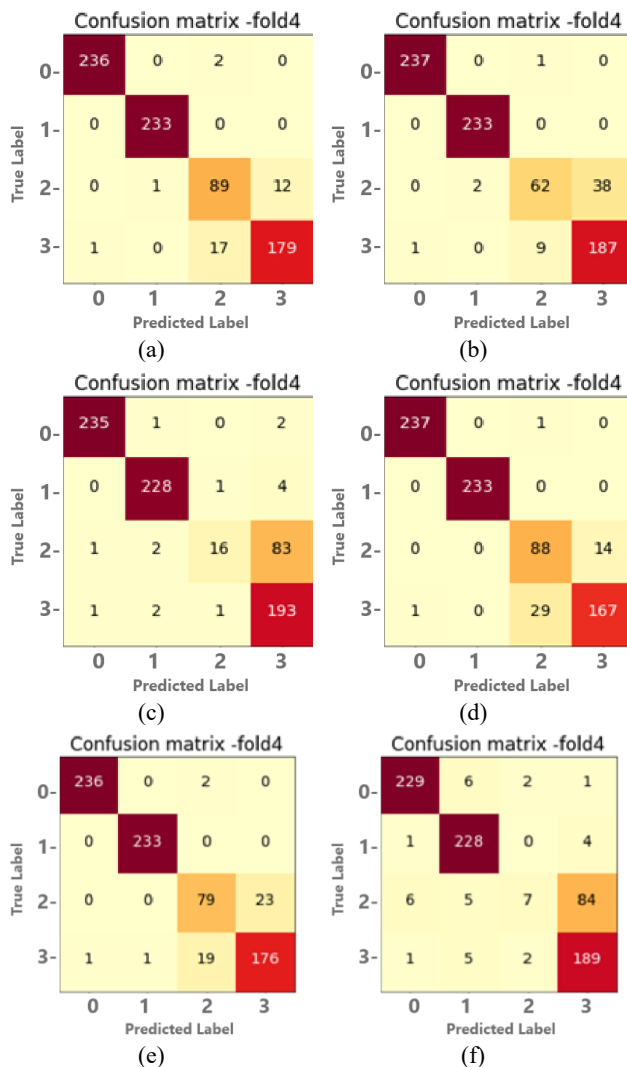
Tabel 1 Skenario Ujicoba

Skenario	<i>Learning rate</i>	<i>Batch size</i>
1	0,001	16
2	0,0001	16
3	0,00001	16
4	0,001	32
5	0,0001	32
6	0,00001	32

Fokus penelitian adalah mencari kombinasi *hyperparameter* yang memberikan kinerja terbaik dalam klasifikasi penyakit daun pada tanaman jagung, dengan tujuan akhir untuk meningkatkan efisiensi dalam mendeteksi dan mengatasi masalah penyakit daun jagung. *Confusion matrix* digunakan untuk meringkas kinerja model klasifikasi yang digunakan. Nilai TP, FP, FN, dan TN didapatkan untuk menghitung nilai evaluasi metrik. Pada *fold 4* mendapatkan hasil rata-rata akurasi tertinggi seperti yang ditunjukkan pada Tabel 2.

Confusion matrix setiap skenario pada *fold 4* dapat ditunjukkan pada Gambar 4 dimana nilai TP, FP, FN, dan TN didapatkan untuk mengevaluasi pada tiap model menggunakan evaluasi metrik, seperti akurasi, presisi, sensitivitas, dan spesifisitas.

Pada Tabel 2 menunjukkan bahwa semua model memiliki nilai akurasi yang dekat satu sama lain. Pada *fold 1* dan *fold 2* nilai tertinggi didapatkan pada skenario-4 masing-masing, 97,99% dan 97,15%. Pada *fold 3, 4, dan 5* di skenario-1 mendapatkan nilai tertinggi pada ketiga *fold* tersebut masing-masing, 98,18%, 97,86%, dan 97,86%.



Gambar 4 Confusion matrix fold 4 Pada Setiap Skenario: a) Skenario 1, b) Skenario 2, c) Skenario 3, d) Skenario 4, e) Skenario 5, f) Skenario 6

Tabel 2 Rangkuman Hasil Akurasi Ujicoba

Skenario	fold 1	fold 2	fold 3	fold 4	fold 5
1	91,18	84,05	98,18	97,86	97,86
2	88,78	94,36	97,21	96,69	95,91
3	93,84	92,41	93,18	93,64	92,47
4	97,99	97,15	97,66	97,08	87,86
5	97,86	93,51	96,30	97,01	96,69
6	92,87	93,45	91,88	92,40	92,14
Rata-rata	93,75	92,49	95,74	95,78	93,82


Hasil rata-rata uji coba model klasifikasi dengan kombinasi nilai *learning rate* dan *batch size* yang ditunjukkan pada Tabel 3 didapati bahwa skenario-5 secara berturut-turut unggul dalam nilai rata-rata akurasi, presisi, dan spesifisitas. Di sisi lain, skenario-4 mendapatkan nilai rata-rata sensitivitas terbaik dari semua skenario. Skenario-5 memperoleh akurasi tertinggi dengan nilai akurasi sebesar 96,27% dengan

kombinasi *hyperparameter learning rate* = 0,0001 dan *batch size* = 32.

Tabel 3 Hasil Rata-rata Evaluasi Model Setiap Skenario

	Rata-rata Akurasi (%)	Rata-rata Presisi (%)	Rata-rata Spesifisitas (%)	Rata-rata Sensitivitas (%)
1	93,82	88,42	96,09	86,94
2	94,59	88,97	96,44	84,55
3	93,11	84,72	95,35	76,29
4	95,55	90,73	97,12	89,32
5	96,27	90,90	97,55	88,13
6	92,55	82,44	94,97	75,08

Sementara itu, kurva ROC pada skenario-5 dapat dilihat pada Gambar 5 yang menunjukkan nilai AUC tertinggi tiap *fold* nya daripada skenario lainnya. Berdasarkan Gambar 5, nilai ROC tertinggi diperoleh pada *fold 1* yaitu sebesar 99,58%.



Gambar 5 Kurva ROC Skenario-5

Tabel 4 Perbandingan metode usulan dengan penelitian sebelumnya

Penulis & tahun	Metode	Akurasi (%)
Sibiya et al. 2019	CNN	92,85
Syarief et al. 2020	AlexNet + SVM	93,5
Wahyuningrum et al. 2021	DenseNet-169	83,5
Wahyuningrum et al. 2023	LF-CNN	94,15
Dash et al., 2023	SVM-DenseNet201	94,6
Wahyuningrum et al. 2024	Metode usulan (EfficientNetB5)	96,27

Hasil klasifikasi penyakit daun jagung menunjukkan bahwa model usulan ini menghasilkan akurasi yang lebih tinggi dibandingkan penelitian-penelitian sebelumnya seperti ditunjukkan pada Tabel 4. Model CNN biasa seringkali mengalami kesulitan dalam membedakan daun bercak abu-abu dan hawar utara. Namun, penggunaan EfficientNetB5 yang telah

dioptimalkan dalam penelitian ini berhasil meminimalkan kesalahan pada kelas-kelas tersebut dibandingkan dengan penelitian sebelumnya.

KESIMPULAN

Dalam penelitian ini, model *deep learning* EfficientNetB5 digunakan untuk melakukan klasifikasi citra penyakit daun tanaman jagung yang terbagi menjadi 4 kelas. Berdasarkan hasil analisis diperoleh skenario-5 dengan *hyperparameter learning rate* = 0,0001 dan *batch size* = 32 mendapatkan hasil kinerja yang terbaik dengan nilai akurasi sebesar 96,27%, presisi sebesar 90,90%, spesifisitas sebesar 97,55%, dan sensitivitas sebesar 88,13%. Sehingga dapat disimpulkan bahwa penentuan nilai *learning rate* = 0,0001 dan *batch size* = 32 merupakan kombinasi yang mendapatkan nilai yang paling optimal pada *training* model. Oleh karena itu, hasil kinerja model yang dilatih sangat dipengaruhi oleh penentuan nilai yang terdapat pada *hyperparameter learning rate* dan *batch size*.

Keterbatasan penelitian ini termasuk keterbatasan jumlah data yang digunakan serta ruang lingkup klasifikasi yang terbatas pada empat kelas. Untuk penelitian selanjutnya, disarankan untuk menggunakan lebih banyak data serta melakukan eksperimen dengan penyakit daun lainnya agar hasil klasifikasi lebih general. Selain itu, eksplorasi model *deep learning* lainnya, seperti EfficientNet varian yang lebih tinggi atau *Transformer-based architecture*, dapat dipertimbangkan untuk mencapai performa yang lebih baik.

UCAPAN TERIMA KASIH

Ucapan terima kasih disampaikan kepada resipositori Mendeley yang telah menyediakan dataset penyakit daun jagung untuk ujicoba metode pada penelitian ini dan LPPM Universitas Trunojoyo Madura yang telah memberikan dana Penelitian Kolaborasi Nasional dengan nomer kontrak 228/UN46.4.1/PT.01.03/2022.

DAFTAR PUSTAKA

- Amzeri, A. (2018). Tinjauan Perkembangan Pertanian Jagung di Madura dan Alternatif Pengolahan Menjadi Biomaterial. *Rekayasa*, 11 (1), 74–86.
- Atila, Ü., Uçar, M., Akyol, K., & Uçar, E. (2021). Plant leaf disease classification using EfficientNet deep learning model. *Ecological Informatics*, 61, 101182.
- Bagas Prakosa, A., & Radius Tanone, dan. (2023). Implementasi Model Deep Learning Convolutional Neural Network (CNN) pada Citra Penyakit Daun Jagung Untuk Klasifikasi Penyakit Tanaman. In *Jurnal Pendidikan Teknologi dan Informasi* (JUKANTI) (Issue 6). <https://www.kaggle.com/datasets/n>
- Chamarty, A. (2020). Fine-Tuning of Learning Rate for Improvement of Object Detection Accuracy. *2020 IEEE India Council International Subsections Conference (INDISCON)*, 135–141.
- Dash, A., Sethy, P. K., Behera, S. K., (2023). Maize disease identification based on optimized support vector machine using deep feature of DenseNet201. *Journal of Agriculture and Food Research*. Vol. 14, 100824.
- Gajowniczek, K., Złabkowski, T., & Szupiluk, R. (2014). Estimating The ROC Curve and Its Significance for Classification Models' Assessment. *Metody Ilościowe w Badaniach Ekonomicznych*, 15(2), 382–391.
- Getharamani, G., & Arun Pandian, J. (2019). Data for: Identification of Plant Leaf Diseases Using a 9-layer Deep Convolutional Neural Network. In *Mendeley Data* (Vol. 1).
- Hassan Mahmud, K., Adiwijaya, & Al Faraby, S. (2019). Klasifikasi Citra Multi-Kelas Menggunakan Convolutional Neural Network. *E-Proceeding of Engineering*, 6(1), 2127–2136.
- Indolia, S., Goswami, A. K., Mishra, S. P., & Asopa, P. (2018). Conceptual Understanding of Convolutional Neural Network- A Deep Learning Approach. *Procedia Computer Science*, 132, 679–688. <https://doi.org/10.1016/j.procs.2018.05.069>
- Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. *Proceedings of the 32 Nd International Conference on Machine Learning*.
- Kandel, I., & Castelli, M. (2020). The effect of batch size on the generalizability of the convolutional neural networks on a histopathology dataset. *ICT Express*, 6(4), 312–315.
- Lu, J., Tan, L., & Jiang, H. (2021). Review on Convolutional Neural Network (CNN) Applied to Plant Leaf Disease Classification. *Agriculture*, 11, 707.
- Sahayak, D. R., Padhy, N., Mallick, P. K., Zymbler, M., & Kumar, S. (2022). Brain Tumor Classification Using Dense Efficient-Net. *Axioms*, 11(1). <https://doi.org/10.3390/axioms11010034>
- Nugroho, A., & Suhartanto, H. (2020). Hyper-Parameter Tuning based on Random Search for DenseNet Optimization. *2020 7th International Conference on Information Technology, Computer, and Electrical Engineering (ICITACEE)*, 96–99.
- Pardani, W. R., Magdalena, R., & Caecar Pratiwi, N. K. (2022). Deep Learning untuk Klasifikasi Glaukoma dengan menggunakan Arsitektur EfficientNet. *ELKOMIKA: Jurnal Teknik Energi Elektrik, Teknik Telekomunikasi, & Teknik Elektronika*, 10 (2), 322. <https://doi.org/10.26760/elkomika.v10i2.322>
- Pratama Putra, I., & Alamsyah, D. (2022). Klasifikasi Penyakit Daun Jagung Menggunakan Metode Convolutional Neural Network. *Jurnal Algoritme*, 2 (2), 102–112. <https://www.kaggle.com/qramkrishna/corn-leaf-infection-dataset>
- Quintal Lauzon, F. (2012). An Introduction to Deep Learning. *The 11th International Conference on Information Sciences*, 1449.
- Sibiya, M., & Sumbwanyambe, M. (2019). A Computational Procedure for the Recognition and Classification of Maize Leaf Diseases Out of Healthy Leaves Using Convolutional Neural Networks. *AgriEngineering*, 1 (1), 119–131.
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45 (4), 427–437.
- Sudjono, M. S. (1988). Penyakit Jagung dan Pengendaliannya. In *Buku Jagung*. Puslitbang Tanaman Pangan.

- Sulistiyorini, T., Sova, E., Sofie, N., & Napitupulu, R. I. (2023). Penerapan Hyperparameter Convolutional Neural Network (CNN) Dalam Membangun Model Segmentasi Gambar Menggunakan Arsitektur U-NET dengan Tensorflow. *Jurnal Ilmiah Informatika Komputer*, 28 (2), 112–121. <https://doi.org/10.35760/ik.2023.v28i2.6959>
- Syarief, M., & Setiawan, W. (2020). Convolutional neural network for maize leaf disease image classification. *Telkomnika (Telecommunication Computing Electronics and Control)*, 18 (3), 1376–1381.
- Tan, M., & Le, Q. (2019). {E}fficient{N}et: Rethinking Model Scaling for Convolutional Neural Networks. *Proceedings of the 36th International Conference on Machine Learning*, 6105–6114.
- Wahyuningrum, R. T., Kusumaningsih, A., Rajeb, W. P., Purnama, I.K.E., Classification of Corn Leaf Disease Using the Optimized DenseNet-169 Model. *ACM International Conference Proceeding Series*, 67-73, In the 9th International Conference on Information Technology (ICIT 2021), December 22–25, 2021, Guangzhou, China.
- Wahyuningrum, R. T., Kusumaningsih, A., Yousi, D. M., Classification of Corn Leaf Diseases using Loss-Fused Convolutional Neural Network. 2023 International Conference on Information Management and Technology (ICIMTech), 24-25 August 2023, Malang, Indonesia.
- Xu, Huang, & Zhang, Y. (n.d.). *Diabetic Retinopathy Progression Recognition Using Deep Learning Method*.
- Zhang, Z. Y., He, X. Y., Sun, X. H., Guo, L. M., Wang, J. H., and Wang, F. S., (2015), “Image Recognition of Maize Leaf Disease Based on GA-SVM,” *Chem. Eng. Trans.*, vol. 46, pp. 199–204.

Halaman ini sengaja dikosongkan